





Pipeline ETL pour données médicales vers Mongo DB

REALISE PAR : ABDULKADIR GUVEN (DATA ENGINEER)
POUR : DATASOLUTECH
DATE : OCTOBRE 2025

Le défi: Scalabilité et Modernisation



The diagram consists of two large, stylized arrow shapes pointing to the right. The left arrow is light purple and contains a white rounded rectangle with the text 'Point de départ :'. The right arrow is dark grey and contains a white rounded rectangle with the text 'Besoins identifiés :'. Both rectangles have a thin blue border. The arrows are positioned such that they appear to be part of a continuous flow from left to right.

Point de départ :

- Data volumineux et en croissance
- Format CSV non adapté pour :
 - Les requêtes complexes
 - Les accès concurrents

Besoins identifiés :

- Scalabilité
- Performance
- Fiabilité
- Sécurité

Objectifs du Projet

Fiabiliser les données


Construire un pipeline ETL

Modéliser les données


Sécuriser l'accès

Explorer le cloud AWS


Architecture de la Solution



Fonctionnement du Pipeline ETL



Modélisation Intelligente des Données



48 896 patients uniques dans 55 500 lignes


Modélisation Imbriquée (embedding)

✓ Avantages:

- Performance lecture
- Atomicité

✗ Inconvénients:

- Limite de taille (16Mo)
- Mises à jour complexes




Modélisation Normalisée (reference)

✓ Avantages:

- Flexible & évolutive

✗ Inconvénients:

- Requêtes complexes
- Consistance applicative



Sécurité : Rôles d'utilisateurs



medical_db

root

- Lecture/écriture

analyste

- Lecture seule

Sécurité : Hachage des mots de passe

Pourquoi


- Sécurité
- Unicité et Intégrité

Comment

- Fonction non réversible
- Ajout d'un sel (empêche attaque arc-en-ciel)

Exemples d'algorithmes

- SHA-256 (utilisé par MongoDB)
- Argon2
- Bcrypt
- MD5 (obsolète)



Options de Déploiement AWS

Service AWS	Rôle Clé	Avantages
Amazon S3	Stockage Fichiers & Backups	Fiable, Économique
Amazon ECS	Orchestration de Conteneurs	Réutilise le code, Scalable
DocumentDB/Atlas	Base de Données "Managée"	Moins de Maintenance, Haute Dispo.



Recommandation Stratégique

Option A

Déploiement Rapide

Stack Docker 100% sur Amazon ECS

✓ **Avantages** : Rapide, réutilisation maximale

✗ **Inconvénient** : Maintenance BDD à notre charge

Option B

Recommandée Long Terme

Application ETL sur ECS + BDD sur Service Managé (Atlas/DocumentDB)

Avantage: Fiabilité maximale, zéro maintenance BDD

ROI : Meilleur retour sur investissement



Conclusion & Prochaines Etapes

Bilan du Projet

- Pipeline Robuste & Configurable
- Modélisation Performante & Justifiée
- Architecture Sécurisée & Documentée
- Vision Claire pour AWS

Prochaines Étapes

- Valider la stratégie avec le client
- Lancer un POC (Proof of Concept) sur AWS
- Définir les rôles applicatifs avec l'équipe dev
- Planifier la migration